

张哲

13160006317
软件工程 • 硕士在读

@ 3220857484@qq.com

南京理工大学



南京理工大学软件工程硕士在读，主要做 LLM Agent 和 AI 应用工程。参与 JF-AIX 企业级 Agent 平台研发，负责 Agent Runtime 上下文工程，落地会话级文档记忆、跨会话长期记忆与产品数据闭环；独立设计并实现 Agentic 教辅内容生产平台，将教材 PDF 解析、结构化切题、多模态质检、人工裁决和安全落库串成完整生产链路。实习中参与航天领域模型管理平台，负责语义检索、推荐和监控模块。

教育背景

- 南京理工大学 • 软件工程 • 硕士在读 2024.09 – 至今
- 南通大学 • 软件工程 • 本科 2019.09 – 2023.06

实习经历

- 中国电子科技集团公司第二十八研究所（智能模型资源管理平台研发实习） 2025.09 – 2026.04
 - 参与航天领域 AI 模型全生命周期管理平台开发，项目覆盖模型、算法、数据集、镜像和部署监控等功能。
 - 基于 Qwen3-Embedding-0.6B + FAISS 实现语义检索；将模型名称、分类、描述、关联数据集和版本说明拼成检索文档，支持用自然语言任务描述召回候选模型。
 - 实现模型资源推荐模块，将用户历史行为、资源类型偏好和近期热度合并排序；对高频推荐结果做用户级 Redis 缓存，减少重复计算和接口抖动。
 - 补充系统运行监控和智能分析能力，基于 psutil 采集 CPU、内存、磁盘、网络等指标，用 DBSCAN 标出异常时段，并用线性回归给出 7 天资源趋势，辅助运维提前发现容量风险。
- 九方智投（JF-AIX 企业级 Agent 数字员工平台研发） 2026.05 – 至今
 - Agent Runtime** 与端云协同：参与构建 Electron + Vue 3 端侧执行域与 NestJS 云侧控制面，基于 Pi Agent SDK 接管自定义 Agent Loop，完善 Tool 循环熔断、参数校验、输出截断续写、Abort 中断及流式事件分发机制，将模型推理、Tool/Skill 执行、人工确认与结果持久化串联为可观测、可中断、可恢复的执行闭环。
 - 会话级多模态文件记忆：面向会话内少量小型文档、图片及表格附件，设计“首轮原始内容注入 → 异步摘要与图片描述 → 后续摘要引用 → 精确信息按需回读”链路；通过 Renderer 会话状态、Electron 本机缓存与 Server Metadata 三级分层管理文件内容和引用，在不引入向量库及文档分块的情况下，实现文件跨轮持续使用和应用重启恢复；基于模型上下文容量动态分配多文件内容预算，并通过 documentId + hash 校验、原子写入及 Draft Session 迁移保障缓存一致性，降低多轮重复传输正文与图片数据带来的 Token 和通信开销。
 - 跨会话长期记忆：设计与会话文件记忆相互隔离的用户长期记忆链路，每轮结束后异步提炼 user、feedback、project、reference 四类稳定事实，以 MySQL 持久化并通过 Elasticsearch 向量检索召回候选记忆，再由 LLM 结合当前任务进行相关性严选；按用户与 Agent 作用域注入 L6 动态上下文，减少无关记忆干扰，避免临时文件内容进入长期记忆导致事实污染。
 - 产品可观测性与数据闭环：围绕启动、活跃、会话、消息、文件、专家/助手、技能及应用等核心域建立 12 类标准事件；Desktop 侧采用本地持久化队列，每 30 秒批量刷新、单批处理 100 条、最多保留 2,000 条并支持离线重试，Server 侧基于业务事实异步派生事件并通过 dedupHash 实现幂等去重；埋点与分析异常不阻塞核心业务链路，同时避免采集消息正文和文件内容等敏感数据。

项目经历

- ▶ **Agentic 教辅内容生产平台（智能切题 · 多模态质检 · Human-in-the-loop）** 2026.02 – 至今
 - 面向教辅录题场景独立设计并实现 Agent workflow，将教材 PDF 解析、结构化切题、AI 质检、人工裁决、安全落库串成完整生产链路，把传统人工录题升级为“Agent 生成 + AI 复核 + 人工兜底”；平台累计承载 6,862 本教材、72.9 万页 PDF、125.2 万道题目，其中 6,219 本完成抽检、3,081 本完成正式入库。技术栈：Vue 3 / Fastify / PostgreSQL / Redis / BullMQ / MinerU / 火山方舟。
 - **Detector → Verifier → Executor 多阶段质检 Agent**: Detector 使用文本模型批量扫描 OCR 与题目内容，输出包含问题位置、原文、修改建议及可修复性的结构化问题单；Verifier 调用多模态视觉模型，对照 MinerU 坐标实时裁剪的 PDF 原图逐条复核，过滤缺乏原图依据的文本幻觉；Executor 在写回前执行原文唯一定位、内容哈希及稿件版本校验，仅允许通过校验的问题自动修复，其余降级人工处理，并与 revision / 编辑锁联动形成 Human-in-the-loop 闭环。AI 质检上线后已覆盖 80 本教材、14.4 万道题，发现约 1.5 万条问题；质检后内容准确率由约 95% 提升至 98%，单本教材平均抽检耗时由 40 min 降至 18 min，降低约 55%。
 - **Grounding 驱动的文档结构化抽取**: 切题 Agent 不直接生成或改写题目正文，而是消费 MinerU 带 ID 的版面块，通过自定义结构化协议输出题号、题干、选项、答案、解析对源块 ID 的引用，再由服务端回填原始文本与坐标，使每个字段均可追溯至 PDF 原始区域；结合目录路径、邻近章节与页面归属约束处理跨页、双栏及章节边界场景，题目页与答案页分离时通过“目录范围 + 题号”完成跨页题答配对，并采用“归属不确定则宁可漏提”的策略降低跨目录误切与重复切题。目前 MinerU 版面解析已稳定处理 2,225 本教材、29.7 万页 PDF。
 - **可恢复、可审计的 LLM Workflow Runtime**: 基于 BullMQ 统一编排 PDF 拆页、MinerU 解析、自动切题、OCR 与 AI 质检等分钟级任务，接口即时返回 jobId，由 Worker 异步消费，并以批次 checkpoint 实现失败断点续跑，已成功批次自动跳过，避免重复执行和重复计费；通过输入内容哈希 + Prompt 版本进行幂等去重，结合 Redis 锁防止并发重复发起。累计支撑 464 万次 OCR 调用、126 亿 Tokens；记录每次调用的模型、Token、费用及 rawResponse，并通过 Prometheus + Grafana 监控任务 P95、队列积压与 Worker 心跳，实现模型调用成本、任务执行链路及运行状态可观测。

竞赛与获奖

- ▶ **多模态视频理解与视觉推理（ICCV 2025 Perception Test Challenge）** 冠军
 - 面向多项选择视频问答中的细粒度视觉辨别、遮挡推理与选项位置偏置问题，基于 Qwen2.5-VL-7B 完成视频问答指令微调，并设计困难题型挖掘、课程学习和选项乱序增强；推理阶段结合题型专用 Prompt、TTA 及多模型按题型集成，最终获得测试集 80.9% 准确率。
- ▶ **“天翼云息壤杯” AI 大赛：大语言模型数学推理** 三等奖
 - 基于 Qwen2.5-Math-72B 蒸馏生成 10 万条 CoT 样本，并用 Math-Verify 与 Qwen2.5-72B 做答案校验；在 8 卡昇腾 910B 环境对 Qwen3-8B 做 LoRA 微调，使数学题正确率从 38% 提升至 62%。
- ▶ **WACV 2025 目标距离估计挑战赛** 冠军
- ▶ **CVPR 2025 少样本目标检测** 三等奖

专业技能

- ▶ **Agent / LLM**: LangGraph、LangChain Tool、MCP、RAG、长上下文压缩、工具安全、JSONL 审计、LoRA 微调、知识蒸馏、vLLM 推理部署。
- ▶ **后端**: Python (FastAPI / Django)、Node.js (Fastify)、RESTful API、SSE、PostgreSQL / MySQL、Redis、Celery / BullMQ、JWT。
- ▶ **前端**: Vue 3、TypeScript、Vite、Element Plus、Pinia、动态路由；了解 React / Next.js。
- ▶ **工程化**: Docker / Docker Compose、MinIO、Prometheus + Grafana、Nginx、Linux 常用部署与排障。