

张哲

13160006317
软件工程 • 硕士在读

@ 3220857484@qq.com

南京理工大学



南京理工大学软件工程硕士在读，方向为 LLM Agent 开发与应用。熟悉 LangGraph 状态图编排、MCP 工具协议与 RAG 检索增强，有 Agent 框架开发、工具插件化、记忆管理与审计监控的实践经验。独立开发开源 Agent 框架 AgentBot，主导教辅录题审核系统开发；在 ICCV 2025、天翼云息壤杯等竞赛中有多模态模型微调、推理增强与模型集成实战经验。技术栈覆盖 Python/Node.js 后端、Vue 3 前端及 Docker 容器化部署。

教育背景

- 南京理工大学 • 软件工程 • 硕士在读 2024.09 – 至今
- 南通大学 • 软件工程 • 本科 2019.09 – 2023.06

实习经历

- 中国电子科技集团公司第二十八研究所（智能模型资源管理平台研发实习） 2025.09 – 至今
 - 参与航天领域 AI 模型全生命周期管理平台开发（Django + Vue 3），负责语义检索、推荐系统、缓存与监控模块。
 - 针对模型资源增长后关键词检索召回率下降的问题，基于 Qwen3-Embedding-0.6B + FAISS 构建语义检索服务，支持自然语言任务描述检索模型库；通过 Django Signal 监听元数据变更触发增量索引重建，索引读写采用快照隔离实现无锁并发，持久化通过原子文件替换保证崩溃一致性。
 - 实现三路混合推荐引擎（协同过滤 + 内容匹配 + 热度排序），引入 Redis 缓存推荐结果，按用户维度设置 TTL 并通过事件驱动主动失效；写入端采用 Pipeline 批量操作降低 RTT，缓存未命中时由 Celery 异步回填，配合分布式锁防止并发穿透。
 - 基于 DBSCAN 聚类对系统 CPU、内存、磁盘、网络、请求延迟 5 维指标进行异常检测，识别偏离正常模式的异常时段；结合线性回归对资源用量做趋势外推，在容量触达阈值前生成预警工单，为运维预留扩容窗口。

项目经历

- AgentBot • 大模型智能体工具 2025.10 – 至今
 - 基于 LangGraph StateGraph 搭建的 CLI Agent，核心是 agent ↔ tools 循环工作流，支持多轮工具调用与条件路由；通过统一的 Provider 工厂适配 OpenAI / Anthropic / 阿里云等 6 家模型 API，运行时可热切换。
 - 记忆分两层：长期记忆用 Markdown 文件存用户偏好，LLM 通过 Tool Call 自己决定什么时候更新，跨会话保留；短期记忆基于 SQLite Checkpointer 存完整对话，按回合切分，超 40 轮后自动让 LLM 把旧对话压缩成摘要再裁掉原文，长对话 Token 用量降低约 60%。
 - 内置 12 个工具（时间、计算器、任务调度、文件读写、Shell 执行等），工具调用走 LangChain @tool 标准接口；文件和 Shell 操作限制在沙盒目录内，通过路径前缀校验拦截穿越，正则匹配拦截 rm -rf 等危险命令，Shell 执行设 60s 超时。
 - 内置知识库子智能体（WikiAgent），支持自动摄入 PDF / URL / 文章并提取实体与交叉引用，写入结构化 Markdown Wiki；设计摄入、查询、健康检查三个专用子智能体分工协作，健康检查可扫描死链、孤立页面与矛盾内容并自动修复；知识库以标准 Markdown 存储，兼容 Obsidian 图谱可视化，支持 OpenAI 兼容的多种 LLM 后端。
 - 所有 LLM 输入、工具调用、工具返回、AI 回复、系统动作共 5 类事件写入 JSONL 审计日志（单例 + 内存队列 + 守护线程异步落盘），配套 Rich 终端可实时查看 Agent 每一步的决策过程。
- 教辅录题审核一体化系统 2025.06 – 至今
 - 原有教辅录题依赖 Excel + 多工具协作，流程碎片化、效率低，需要一套打通上传、录题、质检、入库全链路

的一体化系统。

- 基于 Vue 3 + TypeScript、Fastify + Prisma + PostgreSQL + Redis 开发录题工作台及后端服务，支持 PDF 双栏浏览、框选 OCR、公式渲染、草稿自动保存，打通教材上传到结果入库的完整链路。
- 主导自动切题模块，基于 MinerU 的块级坐标解析与目录分段能力将教材 PDF 转换为结构化内容，结合大模型完成题号、题干、选项、答案、解析抽取，基于“章节标题 + 题号”实现题答配对，生成标注结果回写工作台。
- 基于 BullMQ 承接 PDF 拆页、MinerU 解析与自动切题等长任务，避免重任务阻塞工作台；补充队列监控告警、草稿缓存与历史恢复、提交前校验等机制。
- 设计并落地 Prometheus + Grafana 监控链路，开发 ops-monitor 服务补充 HTTP 请求耗时、队列积压、任务等待/执行时长 P95、Worker 心跳与离线状态等自定义指标；配置 API P95、Worker 离线、机器高 CPU 等告警规则，提升长任务链路的可观测性与异常发现效率。

竞赛与获奖

- › ICCV 2025 感知测试挑战赛：多项选择题视频问答 冠军
 - 针对多项选择题 VideoQA 中细粒度视觉辨别、遮挡推理、视角变换与选项位置偏置问题，基于 Qwen2.5-VL-7B 做指令微调，结合困难题型挖掘与课程学习强化低准确率标签；训练阶段引入选项乱序增强缓解模型记忆选项位置，推理阶段设计题型专用 Prompt、遮挡/视角两阶段推理、TTA 与 GLM-4.5V / Seed-1.6-Vision / Qwen2.5-VL 按题型集成，最终测试集准确率 80.9%。
- › “天翼云息壤杯” AI 大赛：大语言模型数学推理 三等奖
 - 基于 Qwen2.5-Math-72B 蒸馏生成 10 万条 CoT 样本，结合 Math-Verify 与 Qwen2.5-72B 做答案校验；在 8 卡昇腾 910B 环境完成 Qwen3-8B 的 LoRA 微调，数学题正确率从 38% 提升至 62%。
- › WACV 2025 目标距离估计挑战赛 冠军
- › CVPR 2025 少样本目标检测 三等奖

专业技能

- › **Agent** 开发：熟悉 LangGraph 状态图编排（StateGraph、条件路由、ToolNode、Checkpointner），能独立设计带工具调用、多轮循环的 Tool-use Agent；有记忆管理、上下文裁剪、工具安全校验、JSONL 事件审计等工程化实践；熟悉 MCP 协议与技能插件机制，有多模型提供商适配经验。
- › **LLM** 应用：熟悉 LangChain 工具链与 Prompt 设计，具备 RAG（向量召回 + 重排序）、知识蒸馏、LoRA 微调及 GRPO 强化学习实践经验；了解 vLLM 推理部署。
- › **后端开发**：熟悉 Python（FastAPI/Django）和 Node.js（Fastify）后端开发，掌握 RESTful API、SSE 流式接口、PostgreSQL/MySQL、Redis、Celery/BullMQ 消息队列及 JWT 认证。
- › **前端开发**：熟悉 Vue 3 + TypeScript + Vite，了解 React/Next.js；掌握 Element Plus、Pinia、动态路由等工程化实践。
- › **DevOps**：熟悉 Docker/Docker Compose 容器化部署，掌握 MinIO 对象存储、Prometheus + Grafana 监控体系及 Nginx 反向代理。