张哲

13160006317 3220857484@qq.com 南京理工大学
软件工程 • 硕士在读

南京理工大学软件工程硕士在读，聚焦 LLM Agent 系统工程与应用落地。熟悉 LangGraph 状态图编排、MCP 工具协议、双水位记忆与 RAG 检索增强，具备从 Agent 框架自研、工具/技能插件化、全链路审计监控到前端可视化的端到端落地能力。自研开源透明可控 Agent 框架 AgentBot，主导实现 OCR 运维诊断 Agent 与教辅录题审核系统；在模型微调与检索优化方向具备 KDD Cup、天翼云息壤杯等竞赛实战经验。技术栈覆盖 Python/Node.js 后端、Vue 3 前端及 Docker 容器化部署。

教育背景

至今 2024.09	**南京理工大学** • 软件工程专业 软件工程 • 硕士
2023.06 2019.09	**南通大学** • 软件工程专业 软件工程 • 本科

比赛经历

- **KDD Cup 2024 学术论文问答检索挑战赛** 2024.05 – 2024.07
  - **任务背景**: 面向学术问答场景，从海量论文中检索与专业问题最匹配的候选论文，核心挑战在于复杂 Query 冗长、语义匹配困难。
  - **方案设计**: 设计 “问题精炼 + 向量召回 + 重排序” 两阶段检索方案——基于 Llama3 对 Query 精炼总结，使用 BGE M3 统一向量化，结合 FAISS 召回 Top100 候选，再引入 BGE-Reranker 精排筛选 Top20；通过 Hard Example Mining 构建微调数据，对 Reranker 进行专项优化，提升困难样本区分能力。
  - **最终成果**: 官方测试集检索分数从 0.138 提升至 0.166，较基线提升约 20.3%。
- **“天翼云息壤杯” AI 大赛：大语言模型数学推理能力提升** 2024.11 – 2025.07
  - **任务背景**: 基于 Qwen3-8B 开展微调训练，提升模型对复杂数学问题与深度推理的理解求解能力。
  - **方案设计**: 针对数学推理长链路推导困难、监督样本质量不足的问题，设计 “数据蒸馏 + 质量筛选 + 参数高效微调” 整体方案——基于 MetaMathQA 构建数据集，利用 Qwen2.5-Math-72B 蒸馏生成 10 万条高质量 CoT 样本，结合 Math-Verify 与 Qwen2.5-72B 评审模型做答案校验。
  - **工程落地**: 在 8 卡昇腾 910B 64G 环境完成 Qwen3-8B 的 LoRA 微调，结合 vLLM 优化推理性能，实现训推一体化部署。
  - **最终成果**: 微调后客观数学题正确率从 38% 提升至 62%，提升幅度达 63%。

专业技能

- **Agent 开发**: 熟悉 LangGraph 状态图编排（StateGraph、条件路由、ToolNode、Checkpointer），能独立设计带工具调用、多轮循环、可追踪回放的 Tool-use Agent；熟悉两段式工具调用、双水位记忆与上下文裁剪、JSONL 事件审计等 Agent 工程化模式；熟悉 MCP 协议与技能插件机制，具备自定义工具服务及多模型提供商适配经验。
- **LLM 应用**: 熟悉 LangChain 工具链与 Prompt 设计，具备 RAG（向量召回 + 重排序）、知识蒸馏、LoRA 微调及 GRPO 强化学习实践经验；了解 vLLM 推理部署。
- **后端开发**: 熟悉 Python（FastAPI/Django）和 Node.js（Fastify）后端开发，掌握 RESTful API、SSE 流式接口、PostgreSQL/MySQL、Redis、Celery/BullMQ 消息队列及 JWT 认证。
- **前端开发**: 熟悉 Vue 3 + TypeScript + Vite，了解 React/Next.js；掌握 Element Plus、Pinia、动态路由等工程化实践，能实现 Agent 执行过程可视化。

- **DevOps**: 熟悉 Docker/Docker Compose 容器化部署，掌握 MinIO 对象存储、Prometheus + Grafana 监控体系及 Nginx 反向代理。

实习经历

- **中国电子科技集团公司第二十八研究所（智能模型资源管理平台研发实习）** 2025.09 – 至今
  - **项目定位**: 参与面向航天领域的 AI 模型全生命周期管理平台开发，技术栈为 Django + Vue 3，覆盖模型、算法、数据集的版本管理、自动化审核、容器化部署与语义检索，涉及 30+ 数据模型、20+ 前端页面。
  - **语义向量检索引擎**: 针对平台模型资源数量增长后关键词检索召回率不足的问题，基于 Qwen3-Embedding-0.6B 与 FAISS 搭建语义检索服务，支持用户以自然语言任务描述检索模型库；设计增量索引更新机制，通过 Django Signal 监听模型元数据及关联关系变更自动触发重建，避免全量重建开销；索引读写采用 clone-on-read 快照隔离保证搜索无锁并发，持久化通过原子文件替换保证崩溃安全；上线后模型检索从纯关键词匹配升级为语义级召回，用户定位目标模型的平均交互轮次显著减少。
  - **容器化部署与镜像交付**: 基于 Docker SDK 实现模型服务全生命周期管理，涵盖镜像拉取、权重挂载、健康检查，Celery Beat 驱动 60s 周期服务探活与 10min 故障自动恢复；镜像导入采用 download → load → tag → push → register 五阶段状态机，任意阶段失败自动清理本地镜像、tar 文件及 MinIO 临时对象，成功后自动回填版本镜像字段并同步 ImageAsset 记录。
  - **个性化推荐与智能分析**: 实现三路混合推荐引擎——40% 协同过滤基于 Jaccard 相似度衡量用户-资源交互重合度，30% 内容推荐根据用户活跃时段与操作类型分布构建画像匹配资源标签，30% 热度排序综合活跃度、独立用户数、收藏数与下载量加权评分；同时基于 DBSCAN 聚类对系统 5 维指标做异常检测，结合线性回归趋势预测生成容量预警。

项目经历

- **AgentBot ·透明可控 LLM Agent 框架（开源个人项目）** 2025.10 – 至今
  - **项目背景**: 针对 LLM Agent 决策黑箱、工具误用、长对话 Token 爆炸等工程痛点，基于 LangGraph 自研一套面向生产环境的透明可控 Agent 框架，覆盖状态图编排、双水位记忆、可插拔技能、全链路审计监控与心跳任务调度。
  - **Agent 状态图编排**: 基于 LangGraph StateGraph 构建 agent ↔ tools 循环工作流，tools_condition 条件路由支持多轮工具调用与可中断执行；自定义 agent_node 每次推理前动态注入系统 Prompt、用户长期画像与近期摘要；适配 OpenAI / Anthropic / 阿里云 / 腾讯云 / Z.AI / Ollama 等 6 家模型提供商统一抽象，支持热切换。
  - **双水位记忆与上下文裁剪**: 设计 “长期画像 + 近期摘要” 双水位记忆——长期画像以 Markdown 持久化用户静态偏好，LLM 主动调用 save_user_profile 工具更新；短期记忆基于 SQLite Checkpointer 存储完整对话，按 “用户回合”（HumanMessage → AIMessage → ToolMessage）切分，超阈值时旧对话蒸馏为 150 字摘要并经 RemoveMessage 删除，兼顾 Token 控制与语境连续性。
  - **两段式工具调用（help → run）**: 针对 Agent 盲目执行高危命令问题，将每个动态技能封装为 “先读说明书再执行” 的两阶段 Tool，LLM 需先以 mode=help 读取 SKILL.md 再决定是否以 mode=run 执行；自建 10 组破坏性任务评测集验证，P0 级事故率从 50% 降至 10%，安全命中率从 50% 提升至 90%。
  - **可插拔技能与 MCP 生态**: 实现 SKILL.md 动态扫描加载器，通过 StructuredTool + Pydantic Schema 自动注册为 LangChain Tool，兼容 OpenClaw 与 Claude Code 两大技能生态；通过 mcporter 接入外部 MCP 服务，内置 skill-creator / skill-vetter 支持自然语言生成与安全审查技能。
  - **可观测性与沙盒安全**: 自研 JSONL 审计日志器（单例 + 内存队列 + 守护线程异步落盘），记录 llm_input / tool_call / tool_result / ai_message / system_action 五类事件，配套 Rich 监控终端实时回放决策链路；基于 asyncio 协程实现心跳任务调度器，支持 daily/weekly/monthly 续期；沙盒层跨平台拦截路径越权与危险 Shell 命令，保障非交互式自动化执行安全。
- **OCR 运维诊断 Agent（DeerFlow / LangGraph）** 2026.01 – 至今
  - **项目背景**: 面向 OCR 服务运维场景，运维人员需要快速定位告警根因并获取处置建议，传统人工排查效率低、依赖经验。
  - **诊断链路设计**: 基于 DeerFlow / LangGraph 构建 Triage → Diagnosis → Report 三阶段工作流，支持自然语言输

入告警或排障问题，自动完成告警分类、证据收集、根因分析与处置建议生成。

- **工具接入与分析**: 接入 Prometheus 指标查询、Docker 容器状态与日志采集、历史案例检索等诊断工具，覆盖 API P95、队列 waiting/failed/workers、CPU/内存占用等关键证据；Diagnosis 阶段采用规则诊断 + LLM 校对策略，降低纯模型推断的误判风险。
- **可观测性**: 开发 AIOps 诊断台，基于 SSE 展示 Agent 各阶段输入输出与分析过程，支持诊断链路回放，便于故障复盘与演示。

教辅录题审核一体化系统 2025.06 – 至今

- **项目背景**: 原有教辅录题依赖 Excel + 多工具协作，流程碎片化、效率低，需要一套打通上传、录题、质检、入库全链路的一体化系统。
- **主流程建设**: 基于 Vue 3 + TypeScript、Fastify + Prisma + PostgreSQL + Redis 开发录题工作台及后端服务，支持 PDF 双栏浏览、框选 OCR、公式渲染、草稿自动保存，打通教材上传到结果入库的完整链路。
- **结构化自动切题**: 主导自动切题模块，基于 MinerU 的块级坐标解析与目录分段能力将教材 PDF 转换为结构化内容，结合大模型完成题号、题干、选项、答案、解析抽取，基于 “章节标题 + 题号” 实现题答配对，生成包含编号、页码、坐标、题型等字段的标注结果回写工作台。
- **稳定性治理**: 基于 BullMQ 承接 PDF 拆页、MinerU 解析与自动切题等长任务，避免重任务阻塞工作台；补充队列监控告警、草稿缓存与历史恢复、提交前校验等机制，降低卡顿、丢稿和返工风险。

荣誉奖项

- ICCV 2025 感知测试挑战赛：多项选择题视频问答 冠军
- WACV 2025 目标距离估计挑战赛 冠军
- CVPR 2025 少样本目标检测 三等奖
- 天翼云息壤杯高校 AI 大模型比赛（华为） 三等奖